

为什么双曲空间适合

语言特性

观察到的现象：词元向量的出现频率成幂律分布，少数词占据极高出现频率，多数词占据极少频率。在欧氏空间，低频词的范数大，高频词的范数小。高频词（“的”“是”）是**上位概念**，覆盖面广；低频词（“饕餮”）是**下位概念**，含义精确。这天然形成一棵语义树。以上体现了语言的层级结构，即词元嵌入**自发地**在欧氏空间形成了一种类树的层次结构。

树的特性

如果看成树，关心“距离”。一棵树上两个节点的距离=各自到最小公共根节点的距离加和。节点数目随着树的深度成指数级增长。

总结就是：

1.对于节点A，B，存在一个公共的最小节点C（连通性保证存在， $d(A,B)=d(A,C)+d(B,C)$ ），路径： $A \leftrightarrow C \leftrightarrow B$

推论 若AB位于同一层，C位于其上层。 $d(A,C)=D(B,C)=$ 层数之差

2.节点数目随着层数成指数级别增长

基于1，树的同一层节点应该分布在一个圆形上，整棵树应该呈现同心圆。

把距离原点的长度视为深度，画圆，那么节点则分布在这个圆上。

考察欧氏空间，圆的周长是线性级别增长的。说明了会随着深度的增长，节点会变得越来越密集，也就是词元之间会变得越来越难以区分。

双曲空间的特性

洛伦兹模型下的度量公式：

$$ds^2 = dr^2 + \sinh^2(r)d\theta^2$$

进而推导周长：

$$C(r) = \int_0^{2\pi} \sinh(r) d\theta = 2\pi \sinh(r) \sim \pi e^r$$

双曲空间的周长指数增长，和树的节点数指数增长速度匹配，保证了嵌入时节点之间的距离不会随层数加深而急剧压缩。

数学对象的理解

闵可夫斯基空间

1.来源：为了用数学语言描述爱因斯坦的相对论。

2.定义：

相对论揭示了，时间和空间都会因为参考系的不同而不同，但是光速不会，也就是时空间隔。可以组合出一个不变量，在闵可夫斯基空间内，定义为**时空间隔**：

$$s^2 = -c^2 \Delta t^2 + \Delta x^2 + \Delta y^2 + \Delta z^2$$

接着，仿照欧氏空间的内积，定义闵可夫斯基空间的内积。

$$\langle x, x \rangle_L = -x_0^2 + x_1^2 + x_2^2 + \cdots + x_n^2$$

$$\langle x, y \rangle_L = -x_0 y_0 + x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

x 和 x 做洛伦兹内积具有物理意义，就是闵可夫斯基空间的距离

x 和 y 做洛伦兹内积，暂时没有想到物理意义，只是作为工具的推广

$$\langle x, x \rangle_L < 0 \quad \text{类时}$$

$$\langle x, x \rangle_L = 0 \quad \text{类光}$$

$$\langle x, x \rangle_L > 0 \quad \text{类空}$$

3.推导

利用类时向量得到一个“双曲面”，这样的曲面才能容纳指数级增长的节点

$$L_K^n = \{x \in \mathbb{R}^{n+1} : \langle x, x \rangle_L = -K, \quad x_0 > 0\}$$

从闵可夫斯基度量推导双曲度量

背景度量与约束

闵可夫斯基背景度量：

$$ds^2 = -dx_0^2 + dx_1^2 + dx_2^2$$

对空间分量做极坐标换元，令 $\rho = \sqrt{x_1^2 + x_2^2}$ ，由双曲面约束 $\langle x, x \rangle_L = -1$ 得 $x_0 = \sqrt{1 + \rho^2}$ ，代入背景度量化简得：

$$ds^2 = \frac{1}{1 + \rho^2} d\rho^2 + \rho^2 d\theta^2$$

从欧氏径向距离换成测地距离

ρ 是空间分量的欧氏长度，不是曲面上的距离。沿径向（ $d\theta = 0$ ）从原点积分，算出真正的测地距离 r ：

$$r = \int_0^\rho \frac{1}{\sqrt{1 + \rho'^2}} d\rho'$$

令 $\rho' = \sinh(u)$ ，则：

$$d\rho' = \cosh(u) du, \quad \sqrt{1 + \rho'^2} = \cosh(u)$$

代入：

$$r = \int_0^{\operatorname{arcsinh}(\rho)} \frac{\cosh(u)}{\cosh(u)} du = \operatorname{arcsinh}(\rho)$$

因此：

$$\rho = \sinh(r), \quad d\rho = \cosh(r) dr, \quad 1 + \rho^2 = \cosh^2(r)$$

代入得双曲度量

$$ds^2 = \frac{\cosh^2(r)}{\cosh^2(r)} dr^2 + \sinh^2(r) d\theta^2$$

$$\boxed{ds^2 = dr^2 + \sinh^2(r) d\theta^2}$$

空间的度量：

在这里，仔细区分一下，闵可夫斯基空间的度量，欧氏空间的度量，庞加莱模型的度量，以及在闵可夫斯基空间下的双曲度量，欧氏空间的球度量，庞加莱模型的双曲度量。以及各自的测地距离。

这个问题需要从勾股定理的成立性说起，我发现我难以回答这个问题。勾股定理就是欧氏空间的度量，它是基于欧氏空间才成立的，欧氏空间的距离，也都是因此基于勾股定理建立的。也就是，可以构建一种不同于欧氏空间的空间，非欧空间。

它遵守的是另一套“勾股定理”。

欧氏空间的度量：

$$ds^2 = dx_1^2 + dx_2^2 + \cdots + dx_n^2$$

其实准确来说，欧氏空间的度量先于勾股定理，勾股定理只是欧氏空间度量的直觉理解。

庞加莱模型的度量：

$$ds^2 = \frac{4K}{(1 - \|x\|^2)^2} (dx_1^2 + dx_2^2)$$

我比较容易接受，因为其几何意义比较直观，可以看作是两个欧氏距离的比，揭示了，越远离原点，它的“距离”会相较正常的欧氏距离更大。

而闵可夫斯基空间的度量：

$$ds^2 = -dx_0^2 + dx_1^2 + dx_2^2 + \cdots + dx_n^2$$

虽然取之于相对论中的绝对不变量，但是没有明确的几何直觉，我就一时很难接受

但是后面想明白了一些，这些是描述了如何在一个空间内定义“距离”，是一把**尺子**

查了准确的定义：

度量张量

度量张量是定义在流形每一点切空间上的**对称双线性型**，用来给出向量的内积，从而定义长度和角度。

- **流形**：广义上的“空间”，比如欧氏空间、球面、双曲面都是流形。
- **切空间** $T_p M$ ：在点 p 处，所有“从 p 出发的无穷小方向”构成的向量空间。直觉上就是“在这一点，你可以朝哪些方向走一小步”。
- **对称双线性型**：接收两个切向量 u, v ，吐出一个实数，满足对称性 $g_p(u, v) = g_p(v, u)$ 和线性性。行为类似内积。

由内积导出长度：

$$ds^2 = g_p(v, v)$$

这就是度量公式 $ds^2 = dx_1^2 + dx_2^2$ 的来源——它是度量张量作用在位移向量上的结果。

逐点定义：度量张量在每一点单独定义，直觉上是“每一点配备一把自己的尺子”。在欧氏空间里每一点的尺子相同；在双曲面上，尺子随位置变化，这正是 $\sinh^2(r)$ 随 r 变化的原因。

根据正定性分两类：

- **黎曼度量**： $g_p(v, v) > 0$ 对所有非零 v 成立，长度恒正。欧氏空间、球面、双曲面均属此类。
- **伪黎曼度量**： $g_p(v, v)$ 可正可负。闵可夫斯基空间属此类，负号携带的是类时/类空的物理信息，不是距离的概念。

建立起了一个空间具体流形的度量的计算过程：

确定空间度量->结合流形的方程->流形上的度量

测地距离：

在流形张量下的，流形上两点的最短距离

大概就是，取微元，表示路径，然后用变分法，求出最短的**路径长度**。

这条路径就被称作测地线，在欧氏空间中，两点之间线段最短，所以就是直线，但是流形上则未必。

洛伦兹内积

直接计算测地距离，显然很难。

类比欧氏空间中，球的测地距离和点积的关系

欧氏空间球面的测地距离

$$d(x, y) = R \cdot \arccos \left(\frac{\langle x, y \rangle}{R^2} \right)$$

其中 $\langle x, y \rangle = \sum_i x_i y_i$ 为欧氏内积， $\|x\| = \|y\| = R$ 。

双曲面（洛伦兹模型）的测地距离

$$d(x, y) = \sqrt{K} \cdot \operatorname{arccosh} \left(\frac{-\langle x, y \rangle_L}{K} \right)$$

其中 $\langle x, y \rangle_L = -x_0 y_0 + \sum_{i=1}^n x_i y_i$ 为洛伦兹内积， $K > 0$ 为曲率参数。

两者结构完全平行：球面用欧氏内积取 $\arccos$ ，双曲面用洛伦兹内积取 $\operatorname{arccosh}$ ，负号来自洛伦兹内积在双曲面上恒为负。

双曲空间和欧氏空间的连接

从欧氏空间到双曲空间

欧氏向量 $x \in \mathbb{R}^n$ 本身不在双曲面上，需要映射到 L_K^n 。有两种方法。

方法一：直接升维约束

$$x = (x_1, \dots, x_n) \mapsto \left(\sqrt{K + \|x\|^2}, x_1, \dots, x_n \right)$$

直接补充一个时间分量 $x_0 = \sqrt{K + \|x\|^2}$ ，使得：

$$-x_0^2 + \|x\|^2 = -(K + \|x\|^2) + \|x\|^2 = -K$$

满足双曲面约束 $\langle x, x \rangle_L = -K$ 。

直觉：把欧氏向量"抬"到双曲面上，时间分量由空间分量唯一确定，不引入额外自由度。

方法二：指数映射

在点 $o = (\sqrt{K}, 0, \dots, 0)$ 处的切空间里，取切向量 $v = (0, u)$ ， $u \in \mathbb{R}^n$ ，指数映射为：

$$\exp_o^K(v) = \left(\sqrt{K} \cosh \left(\frac{\|u\|}{\sqrt{K}} \right), \sqrt{K} \sinh \left(\frac{\|u\|}{\sqrt{K}} \right) \frac{u}{\|u\|} \right)$$

直觉：切空间是贴在双曲面原点处的欧氏平面，指数映射沿测地线把切向量"推"到双曲面上，距离原点越远，双曲函数的指数增长越明显。

δ -双曲性

1 为什么需要判断"数据是否适合双曲空间"

双曲空间能高效表示层次结构，但不是所有数据都有层次结构。在使用双曲微调之前，需要一个定量指标来回答：


"这个词元嵌入到底有没有层次结构？如果有，有多强？"

δ -双曲性就是这个指标。它衡量一个度量空间与树的偏离程度。

2 核心证明：基于公共汇聚点的代数推导

在树状空间中，任意三个点 u, v, x 的路径必然汇聚于一个唯一的交汇点 O 。我们通过这个“星型结构”来证明为什么其 δ 必然为 0。

1. 几何模型



2. 构建距离矩阵

在树上，任意两点间的距离必须通过交汇点 O 进行转接：

- 点对距离：($a < b < c$)

- $d(u, v) = a + b$

- $d(u, x) = a + c$

- $d(v, x) = b + c$

我只能理解这个公式的成立

$$d(u, v) \leq \max(d(u, x), d(v, x))$$

- 到观察者 w 的距离：

- $d(u, w) = a + d$
- $d(v, w) = b + d$
- $d(x, w) = c + d$

3. 代数推导 (Gromov 积计算)

代入 Gromov 积公式 $(u|v)_w = \frac{1}{2}[d(u, w) + d(v, w) - d(u, v)]$ ：

$$\begin{aligned}(u|v)_w &= \frac{1}{2}[(a + d) + (b + d) - (a + b)] \\ &= \frac{1}{2}[2d + a + b - a - b] \\ &= d\end{aligned}$$

同理可得：

- $(u|x)_w = \frac{1}{2}[(a + d) + (c + d) - (a + c)] = d$
- $(v|x)_w = \frac{1}{2}[(b + d) + (c + d) - (b + c)] = d$

4. 验证 δ -双曲性不等式

定义要求： $(u|v)_w \geq \min\{(u|x)_w, (v|x)_w\} - \delta$

代入推导结果：

$$d \geq \min\{d, d\} - \delta \implies d \geq d - \delta$$

结论：

在树状结构中，无论分叉的边长 a, b, c 如何变化，它们在计算 Gromov 积时都会被完美抵消。这意味着不等式在 $\delta = 0$ 时精确成立。

低秩变换

为什么“低秩打补丁”(LoRA) 行得通？

在 HypLoRA 或任何基于 LoRA 的微调中，我们都会冻结原始的巨大权重矩阵 $W \in \mathbb{R}^{d \times k}$ ，而是旁路学习一个极小的增量补丁 $\Delta W = BA$ ，使得输出变成 $z = Wx + BAx$ 。其中 $A \in \mathbb{R}^{r \times d}$ ， $B \in \mathbb{R}^{k \times r}$ ，且秩 $r \ll \min(d, k)$

为什么这种“加补丁”的方式不仅可行，而且效果极好？这背后的理论支撑主要有以下三点：

1. 预训练模型的“内在维度”(Intrinsic Dimension) 极低

- **过参数化 (Over-parameterization)**: 预训练模型 (如 LLaMA、Gemma) 拥有数百亿参数，它们在预训练阶段被暴力扩展，是为了具备“记住”全世界所有通用知识和语言范式的能力。
- **任务适配的低秩性**: 一旦模型预训练完成，当你试图让它学习一个**特定的下游任务** (比如专攻数学推理、常识推理，或者像本论文一样赋予它双曲几何视角) 时，所需的“权重更新量”实际上是被限制在一个极低维度的子空间里的。
- **直觉比喻**: 预训练的 W 就像一本极其厚重的《大英百科全书》。当我们要用它来做一本“微积分辅导册”时，不需要重写整本百科全书 (全量微调)，只需要在旁边附带一本只有几页纸的“勘误表与指南” (低秩补丁 BA) 即可。

2. 矩阵分解的“信息漏斗”效应

我们来看补丁 $\Delta Wx = B(Ax)$ 的计算流图：

1. **降维投影 (特征提取)**: 向量 x 首先乘以矩阵 A 。因为 A 的行数 r 极小 (通常只有 8、16 或 64)，这一步就像一个**极度严苛的漏斗**，强制把 d 维的高维输入压缩成 r 维。只有对当前下游任务**最核心、最关键的特征**才能挤过这个漏斗。
2. **升维重构 (特征注入)**: 挤过来的 r 维核心特征，再乘以矩阵 B 放大回 k 维。这一步将提取出的“纯粹任务指令”重新铺展，形成最终的残差更新量。
3. **防过拟合**: 正是因为这个“漏斗”的存在，模型根本没有多余的参数去死记硬背训练集里的噪声。低秩变换天然自带一种强大的正则化效果。

论文核心逻辑

传统方法的局限

1. 单层：传统的双曲切空间变换流程

$$\begin{array}{ccc}
 \underbrace{\mathbb{R}^n}_{n\text{维欧氏空间}} & \xrightarrow{\exp_o} & \underbrace{\mathcal{L}_K^n \subset \mathbb{R}^{n+1}}_{n+1\text{维闵可夫斯基双曲面}} \\
 & \xrightarrow{\log_o} & \underbrace{\mathcal{T}_o \mathcal{L}_K^n \cong \mathbb{R}^n}_{n\text{维欧氏切空间}} \\
 & \xrightarrow{\text{Linear}(W)} & \underbrace{\mathcal{T}_o \mathcal{L}_K^n \cong \mathbb{R}^n}_{\text{线性变换后}} \\
 & \xrightarrow{\exp_o} & \underbrace{\mathcal{L}_K^n \subset \mathbb{R}^{n+1}}_{n+1\text{维闵可夫斯基双曲面}} \\
 & \xrightarrow{\text{Proj}} & \underbrace{\mathbb{R}^n}_{n\text{维欧氏空间}}
 \end{array}$$

2. 多层：深度双曲神经网络（HNNs）的传递坍缩

为了凸显连续层之间“指数映射”与“对数映射”的反复横跳，我们可以将其写为层级传递的公式：

$$\text{空间初始化: } \underbrace{\mathbb{R}^n}_{n\text{维欧氏空间}} \xrightarrow{\exp_o} \underbrace{\mathcal{L}_K^n \subset \mathbb{R}^{n+1}}_{n+1\text{维闵可夫斯基双曲面}}$$

$$\text{第一层变换: } x^H \xrightarrow{\log_o} \mathcal{T}_o \xrightarrow{BA_1} \mathcal{T}_o \xrightarrow{\exp_o} y^H$$

$$\text{第二层变换: } y^H \xrightarrow{\log_o} \mathcal{T}_o \xrightarrow{BA_2} \mathcal{T}_o \xrightarrow{\exp_o} z^H$$

$$\text{输出与降维: } z^H \xrightarrow{\text{Proj}} \underbrace{\mathbb{R}^n}_{n\text{维欧氏空间}}$$

3. “死亡陷阱”的数学证明：从 x 到 z 的坍缩

假设输入特征 x 位于原点 o 处的切空间（即欧氏空间 $\mathcal{T}_o \mathcal{L}_K^n \cong \mathbb{R}^n$ ）中。我们来看看标准双曲神经网络（HNNs）处理多层线性变换时会发生什么。

1. 第一层变换

我们将 x 乘以权重矩阵 BA_1 （此时在切空间内），然后用指数映射 $\exp_o$ 推到双曲面上，得到第一层输出 y^H ：

$$y^H = \exp_o(BA_1 x)$$

2. 第二层变换

为了对 y^H 进行第二层变换，传统方法必须先用对数映射 $\log_o$ 把它拉回切空间，乘以权重 BA_2 ，再用 $\exp_o$ 推回双曲面，得到输出 z^H ：

$$z^H = \exp_o \left(BA_2 \cdot \log_o(y^H) \right)$$

3. 代入与抵消（坍缩开始）

我们将第一层的 y^H 完整代入第二层的公式中：

$$z^H = \exp_o \left(BA_2 \cdot \log_o \left(\exp_o(BA_1 x) \right) \right)$$

对数映射和指数映射互为逆映射，即对于切空间中的任意向量 v ，恒有 $\log_o(\exp_o(v)) = v$ 。因此，中间的两个映射完美抵消：

$$z^H = \exp_o \left(BA_2 \cdot (BA_1 x) \right)$$

$$z^H = \exp_o \left((BA_2 BA_1) x \right)$$

4. 最终输出降维

如果在此处结束网络，将结果映射回欧氏空间（即 LLM 下一层的输入 z ）：

$$z = \log_o(z^H) = \log_o\left(\exp_o(BA_2BA_1x)\right)$$

再次发生抵消：

$$z = BA_2BA_1x$$

🔗 结论：双曲几何的“虚假繁荣”

[cite_start]从最终等式 $z = BA_2BA_1x$ 可以清晰地看出：无论你在中间穿插了多少次看起来很高大上的 $\exp_o$ 和 $\log_o$ ，只要连续变换的路径依赖于切空间，整个网络就会在数学上坍缩为一个纯粹的欧氏空间线性映射 [cite: 82, 83]。

这个过程与双曲空间的负曲率 K 毫无关系，完全等价于没做任何双曲操作。这正是为什么 HypLoRA 必须提出直接在流形上做变换（LLR）的根本原因！

论文提出的方法

3. 破局：HypLoRA 的直接洛伦兹低秩变换（LLR）

为了彻底避开切空间带来的“抵消陷阱”，这篇论文提出将 LoRA 补丁的计算完全隔离，并设计了直接在洛伦兹双曲流形上运行的变换。前向传播被拆分为“欧氏基座”与“双曲增量”双流结构：

$$\text{最终输出: } z^E = \underbrace{Wx^E}_{\text{冻结的欧氏线性基座}} + \underbrace{\Delta z^E}_{\text{保留双曲偏置的低秩增量}}$$

$$\begin{aligned} \text{双曲增量流: } & \underbrace{x^E}_{d\text{维欧氏空间}} \xrightarrow{\Pi_{\text{exp}}^K} \underbrace{x^H \in \mathcal{L}_K^d \subset \mathbb{R}^{d+1}}_{d+1\text{维洛伦兹双曲面}} \\ & \xrightarrow{\text{LLR}(BA, \cdot)} \underbrace{z^H \in \mathcal{L}_K^d \subset \mathbb{R}^{d+1}}_{\text{直接在流形内完成低秩变换}} \\ & \xrightarrow{\Pi_{\text{log}}^K} \underbrace{\Delta z^E}_{d\text{维欧氏切空间/增量}} \end{aligned}$$

4. LLR 的内部解剖：空间变换与时间重构

在上述的数据流中，最核心的黑盒是 LLR（Direct Lorentz Low-Rank Transformation）。为了让经过 BA 线性变换后的点不飞出双曲面，算法巧妙地对 $d+1$ 维的时空坐标进行了解耦处理：

输入分解: $x^H = (\underbrace{x_0^H}_{\text{时间分量}}, \underbrace{x_s^H}_{\text{空间分量}}) \in \mathbb{R}^{1+d}$

步骤 1 (空间变换): $z_s^H = \underbrace{BAx_s^H}_{\text{仅对空间分量应用欧氏低秩矩阵乘法}}$

步骤 2 (时间重构): $z_0^H = \sqrt{\underbrace{\|z_s^H\|_2^2 + K}_{\text{依据 } (z_0^H)^2 - \|z_s^H\|_2^2 = K \text{ 流形约束反推}}}$

组合输出: $\text{LLR}(BA, x^H) = (z_0^H, z_s^H)$

✓ HypLoRA 成功的数学本质

观察 LLR 的解剖过程可以发现, 这里没有任何对数映射 ($\log_o$) 的参与。

1. 我们在“空间分量”上享受了普通 LoRA 矩阵乘法 BA 的高效与便捷。
2. 我们通过重算“时间分量”, 强行将被拉伸变形的向量“摺”回了洛伦兹双曲面上。
3. 正因为变换完全在流形内部闭环, 原本 $\log_o(\exp_o(\cdot))$ 的连续逆映射被硬生生切断, 双曲几何特有的“高阶树状特征 (依赖于词元范数 $\|x\|^2$ 的惩罚项)”得以完美存活, 并随着 $\Pi_{\log}^K$ 最终注入到 LLM 的干流中。

5. 泰勒展开视角: HypLoRA 与 LoRA 的高阶修正差异

1. 指数映射的非线性放大

设输入词元嵌入为 $x \in \mathbb{R}^d$ 。在将其作为切空间向量 $v = (0, x)$ 映射到双曲面 $\mathcal{L}_K^d$ 时, 精确的指数映射公式为:

$$u^H = \exp_o^K(v) = \left(\sqrt{K} \cosh\left(\frac{\|x\|}{\sqrt{K}}\right), \sqrt{K} \sinh\left(\frac{\|x\|}{\sqrt{K}}\right) \frac{x}{\|x\|} \right)$$

对于较小的值, 我们可以使用泰勒展开进行近似:

- $\cosh\left(\frac{z}{\sqrt{K}}\right) \approx 1 + \frac{z^2}{2K}$
- $\sinh\left(\frac{z}{\sqrt{K}}\right) \approx \frac{z}{\sqrt{K}} + \frac{z^3}{6K^{3/2}}$

代入指数映射公式, 可以得到近似后的空间分量:

$$u_{space}^H \approx x + \frac{\|x\|^2}{6K} x$$

2. LLR 变换与对数映射降维

随后, HypLoRA 对该空间分量进行低秩变换 BA :

$$z_{space}^H = Au_{space}^H \approx BAx + \frac{\|x\|^2}{6K} BAx$$

在经过时间重构，并通过对数映射 $\log_o^K$ 降维回局部切空间（即最终的欧氏输出增量 ΔQ^{Hyp} ）时，由于对数映射的高阶近似化简，最终的增量结果近似等于其空间分量：

$$\Delta Q^{Hyp} \approx BAx + \frac{\|x\|^2}{6K} BAx$$

3. 最终差异：高次项修正的物理意义

相比之下，传统的欧氏 LoRA 仅执行纯线性变换：

$$\Delta Q^{LoRA} = BAx$$

两者的数学差异一目了然：

$$\Delta Q^{Hyp} - \Delta Q^{LoRA} \approx \frac{\|x\|^2}{6K} BAx$$

📖 修正项的几何与语义意义

- 非线性自适应调节：**HypLoRA 引入的高阶修正项与词元的 L_2 范数 $\|x\|^2$ 严格成正比。
- 惩罚边缘节点：**词元范数 $\|x\|$ 越大，说明该词越是处于语义树底层的“低频、具体词汇”（如“苹果”、“狗”）。
- 打破线性瓶颈：**由于修正项的存在，HypLoRA 能够对这些具体的、处于树结构边缘的词元施加更强的关注和变换（更大的残差修正），从而在微调时更精准地捕捉深层的级联关系与复杂推理逻辑。